RFP 분석을 위한 지능형 RAG시스템
(코드잇 6기 1팀)

2026년 02월

INDEX

1. 개요

2. 개발 전략

3. 개발 경과

4. 시연

5. 회고 및 향후 과제

1.개요

1. 시스템 목표

✓ 공공 기관 RFP 문서를 분석하여 사용자로 자연어로 질의시 문서를 분석하여 결과를 제공.

✓ 기존의 Database를 기반으로 하는 경우 자연어 보다는 날짜, 예산, 키워드 매칭으로만 정형화된 질의만 응답만 제공되는 것을 넘어서는 서비스

2. 시스템 개발 환경

✓ openai 서비스 : llm model: gpt-5-mini, embedding model: text-embedding-3-small 제공.(유료 인터넷 서비스)

✓ GCP제공 :

- region : iowa
- CPU : g2-standard (vCpu : 4, Memory : 16GB) x 1
- GPU : L4 x 1
- Ollama 서비스 : llm model: exaone3.5:7.8b, embedding model: bge-m3 (설치 운영)

✓ 개발Tool : vscode/python

3. 개발 및 시스템 구성 방안

✓ 인터넷 서비스 사용 구성 방안 : 데이터 전처리/임베딩/응답을 openai가 제공되는 서비스를 이용한다.

✓ 온프레스미 : ollama 서비스를 이용해서 임베딩/응답을 처리 한다.(GCP이용)

✓ 한글 파일 처리는 한글api를 이용한 pdf변환 이용. 한글파일을 pdf로 저장 후 분석

✓ pdf의 표나 그림은 미리 openai로 미리 요약하여 txt파일로 저장 후 vector생성이 이용.

✓ 로컬 database를 이용, 질의 응답/평가 등에 이용.

4. 시스템의 특장점

✓ 실무에서 바로 사용하는 것으로 구현하는 것을 가정으로 각 기능을 모듈화하여 확장성을 담보하고, 모델구현의 추상화레이어를 두어서 향후에 다른 모델도 추가 용이.

✓ 인터넷 서비스 사용과 클라우드 온프레스미 사용을 선택적으로 사용.

✓ 평가 함수와 스크립트를 제공해서 최적의 옵션 값을 평가 가능토록 함.

✓ SQLite를 이용한 vector저장 및 메타정보 저장으로 질의/응답에 hybrid 로 응답

✓ 전처리로 domain/keyword등을 미리 분석.

2.개발 전략

1. 전처리/database

- ✓ hwp 파일의 pdf변경: Hancom Office API를 이용한 HWP->PDF변환.(같은 파일이름의 pdf로 변경)
- ✓ pdf의 표와 그림을 요약하여 같은파일 이름의 txt로 저장.
- ✓ 도메인/키워드 추출하여 DB 에 저장. 향후 질의 응답에 사용.

2. 모델

- ✓ openai/ollama/huggingface : 3가지를 모두 같은 형태로 서비스할 수 있도록 개발.(base model -> 상속)
- ✓ openai : llm model: gpt-5-mini, embedding model: text-embedding-3-small
- ✓ Ollama 서비스 : llm model: exaone3.5:7.8b, embedding model: bge-m3
- ✓ hugging face : llm model : nlpai-lab/KULLM3 , embedding model : nlpai-lab/KoE5

3. retriever

- ✓ bm25, vector, hybrid, llm, bm25_llm, vector_llm, hybrid_llm 종류로 구현.

4. reranker

- ✓ bge,dense,openapi,ollama,hybrid 종류로 구현.

5. 웹서비스

- ✓ reflex 프레임웍 사용.

▣ 시스템 구성

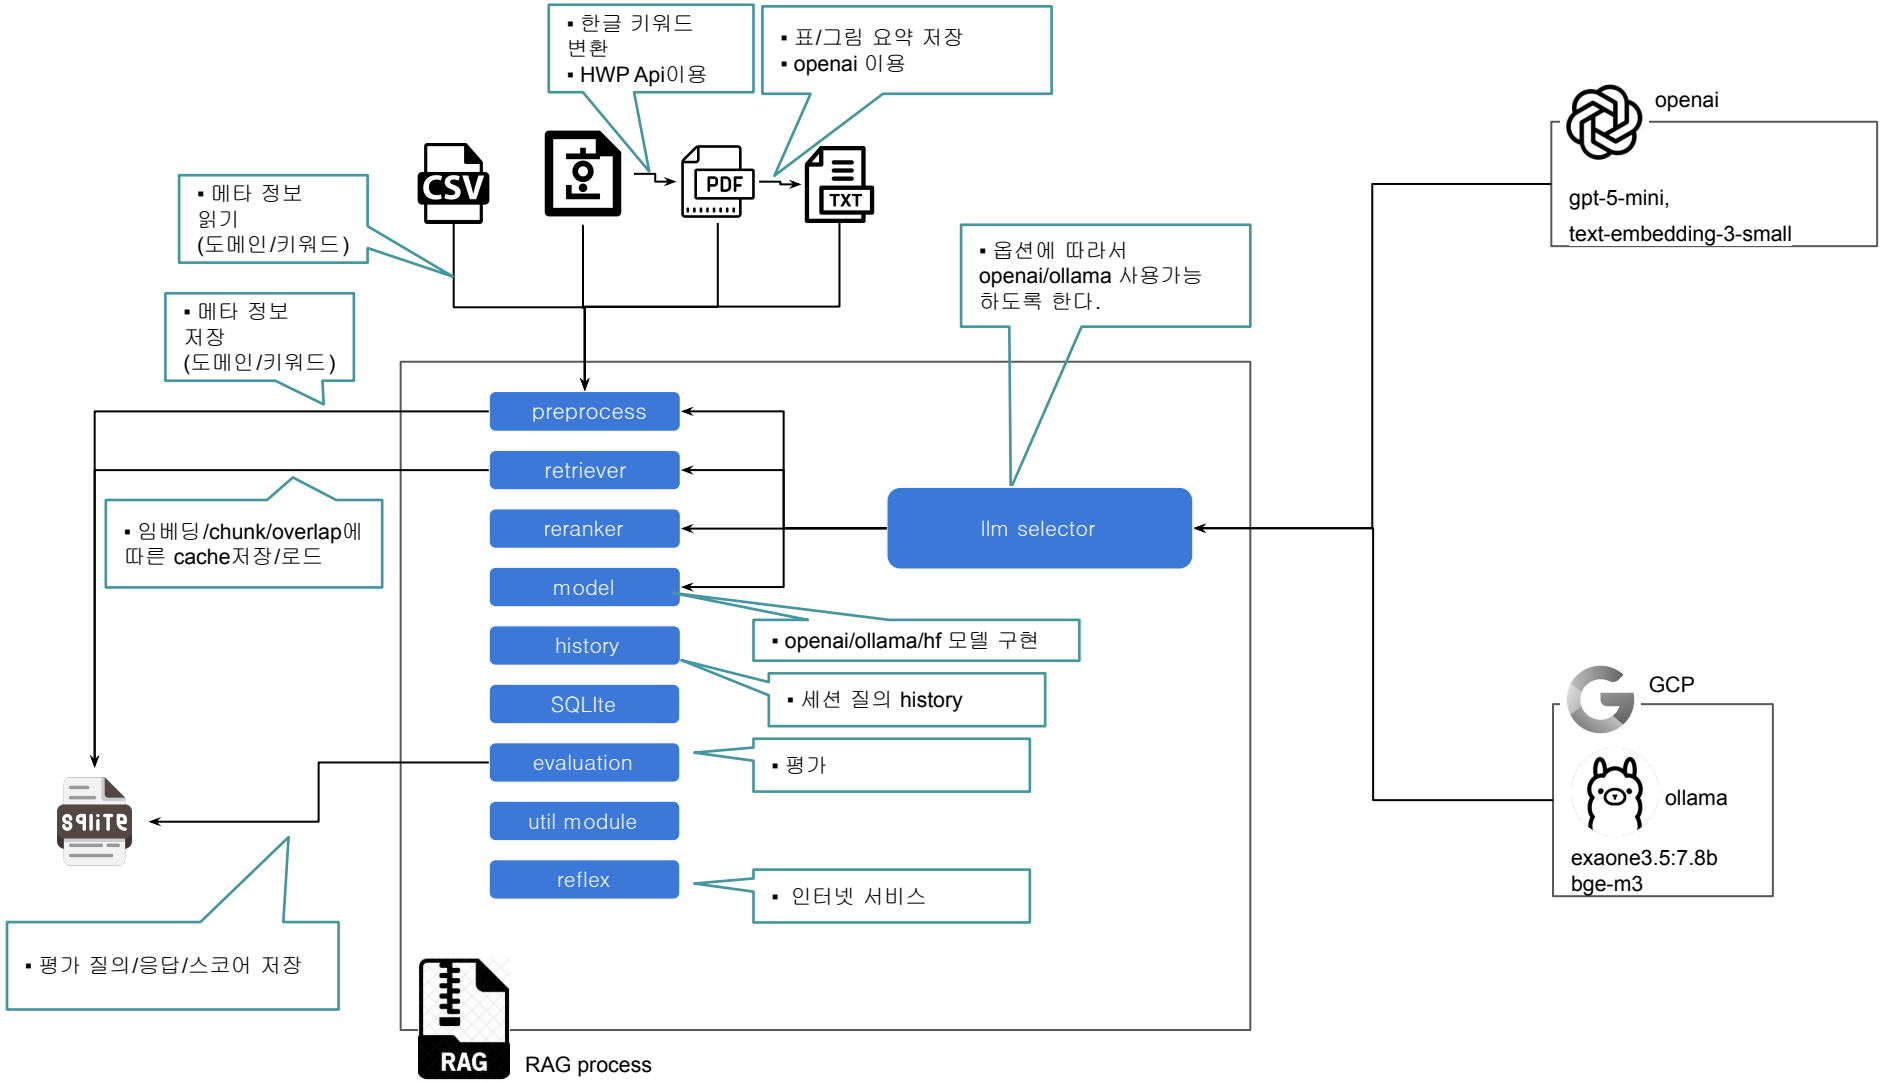
▪ 한글 키워드 변환
▪ HWP Api이용
▪ 표/그림 요약 저장
▪ openai 이용
CSV
PDF
TXT
▪ 메타 정보 읽기 (도메인/키워드)
▪ 메타 정보 저장 (도메인/키워드)
▪ 옵션에 따라서 openai/ollama 사용가능 하도록 한다.
openai
gpt-5-mini,
text-embedding-3-small
preprocess
retriever
reranker
model
history
SQLIte
evaluation
util module
reflex
llm selector
▪ 임베딩/chunk/overlap에 따른 cache저장/로드
▪ openai/ollama/hf 모델 구현
▪ 세션 질의 history
▪ 평가
▪ 인터넷 서비스
GCP
ollama
exaone3.5:7.8b
bge-m3
▪ 평가 질의/응답/스코어 저장
RAG
RAG process

3.2.1. 전처리 개요 < 3.2. 환경 및 전처리 < 3.개발 경과

1. 환경

✓ GCP 기반 환경 구축.
✓ Openai 기반 환경.

2. 전처리/database

✓ hwp 파일의 pdf변경: Hancom Office API를 이용한 HWP->PDF변환.(같은 파일이름의 pdf로 변경)
✓ pdf의 표와 그림을 요약하여 같은파일 이름의 txt로 저장.
✓ 도메인/키워드 추출하여 DB 에 저장. 향후 질의 응답에 사용.

3. HWP -> PDF 저장

✓ 같은 디렉토리에 hwp를 pdf를 저장.
✓ Hancom Office API를 이용해서 저장.

4. Table/Figure 요약

✓ Openai를 이용해서 table/figure 를 요약해서 txt 파일로 저장.

GCP 환경 설정 및 Openai

- ✓ GCP(Google Cloud Platform) 인스턴스 내 Ollama 서버 설치 및 운영.
- ✓ DuckDNS를 이용한 DDNS 설정으로 유동 IP 환경에서도 안정적인 API 엔드포인트 확보.
- ✓ 보안과 비용 효율성을 고려한 'Cloud On-premise' 환경 제공.
- ✓ openai key제공.(인터넷 서비스로 제공 받음)

요약

- ✓ Ollama: 로컬 환경에서 대규모 언어 모델(LLM)을 실행하게 해주는 도구.
- ✓ DuckDns : midprj.duckdsn.org:11434 로 ollama접속 가능.
- ✓ Cloud On-premise: 클라우드 자원을 마치 사내 서버(On-premise)처럼 프라이빗하게 운영한다는 개념.

ollama/vLLM 비교시 선정 이유

구분	Ollama (올라마)	vLLM
주요 목적	**로컬/개인용** 쉬운 실행 및 관리	**기업형/서버용** 고성능 추론 및 서빙
난이도	매우 낮음 (설치 즉시 사용)	보통~높음 (Python/CUDA 환경 설정 필요)
최적화 기술	**GGUF** (양자화 중심, 저사양 최적화)	**PagedAttention** (처리량/속도 극대화)
리소스 요구량	낮음 (일반 PC, MacBook 가능)	높음 (VRAM이 넉넉한 고성능 GPU 권장)
인터페이스	CLI, 자체 API, 다양한 라이브러리 연동	OpenAI 호환 API 서버 중심

ollama 쓰는 이유

- 최적화된 실행 환경.(HuggingFace등으로 직접 모델을 구축할 경우, 모든 것을 수동으로 해야함)
- 양자화 기본 적용.
- 자원의 공유.(ollama서비스를 하므로 GPU를 여러 사람이 쓰는 효과.)
- 보안성과 사내 클라우드나 로컬 네트워크에서 사용 가능.

▣ 전처리 파이프라인

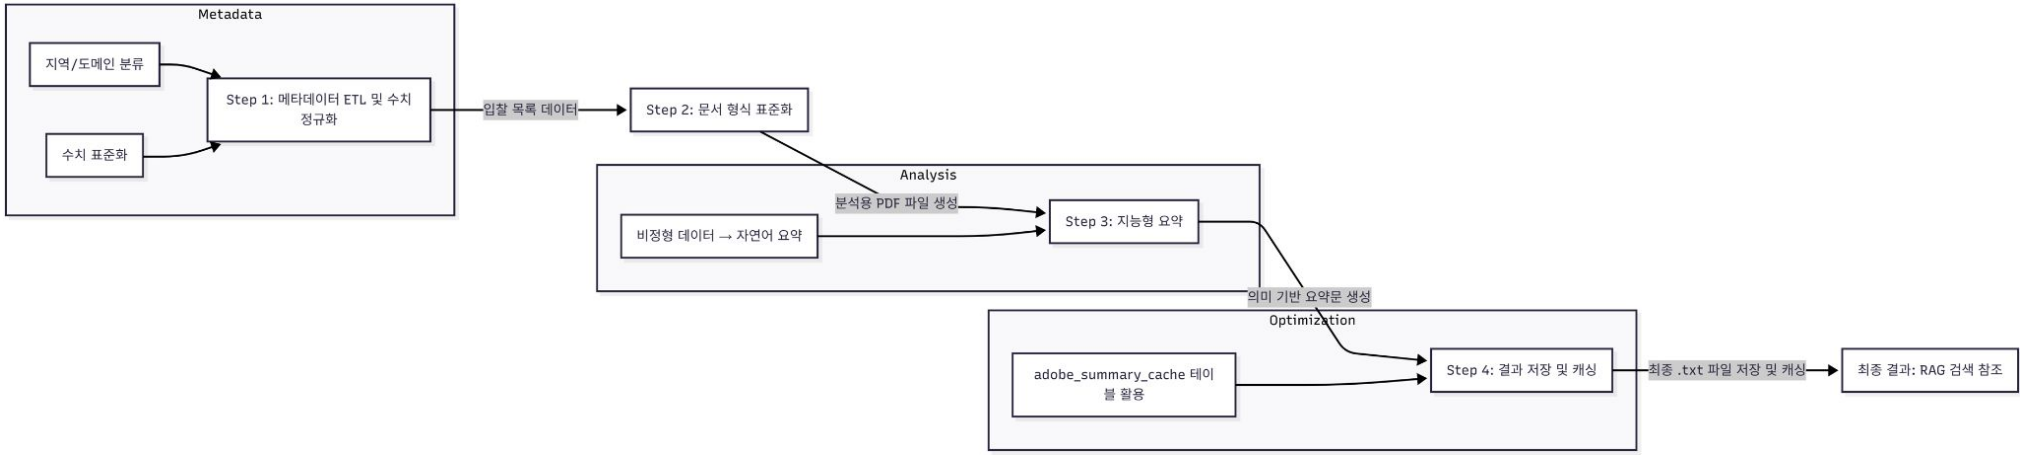

Step	Input	Process	Output
1. 메타데이터 ETL & 수치 정규화	datalist.csv (입찰 목록 데이터)	- 한국어 수치(예: "1억") → 표준 숫자(100,000,000) - 지역/도메인 분류	SQLite rfp_metadata 테이블 저장 (공고번호, 예산, 기관 정보 등)
2. 문서 형식 표준화 (Conversion)	원본 .hwp 파일 (한글 문서)	- HWPConverter 활용 - 분석 호환성 확보를 위해 PDF 포맷 변환	분석용 .pdf 파일 생성
3. 지능형 요약 (Analysis & Summary)	변환된 .pdf 파일	- OpenAI GPT-5-min 활용 - 비정형 데이터(표, 그림 등) → 자연어 요약문 - 단순 텍스트 추출이 아닌 의미 기반 컨텍스트 요약	요약 결과 (텍스트)
4. 결과 저장 및 캐싱 (Output & Caching)	요약 결과	- 물리 .txt 파일 저장 - RAG 검색 참조용 캐싱	최종 .txt 파일

3.2.4. 전처리 통계 < 3.2. 환경 및 전처리 < 3.개발 경과

▣ 파일 통계

1. 파일 개수 요약

✓ Pdf : 4개
✓ Hwp : 96개
✓ Docx : 1개
✓ 총 101개

2. 중복 제거

✓ 고려대학교_차세대 포털·학사 정보시스템 구축사업.docx
✓ 고려대학교_차세대 포털·학사 정보시스템 구축사업.pdf
✓ 동일한 파일 제거로 총 100개의 파일

3. 문서 길이(단어 개수) 및 표 개수

✓ 문서 길이(단어 개수) 또는 표 개수에 따른 RAG 성능 확인
✓ 표 개수가 많은 문서에서의 RAG 성능이 떨어지는지 모니터링

4. 문서당 벡터 유사도

✓ 중복 탐지 및 문서의 군집 구조 파악이 가능
✓ 유사도가 높은 문서가 많으면 RAG성능에 직접 영향을 미침

▣ 문서 길이 및 교 개수

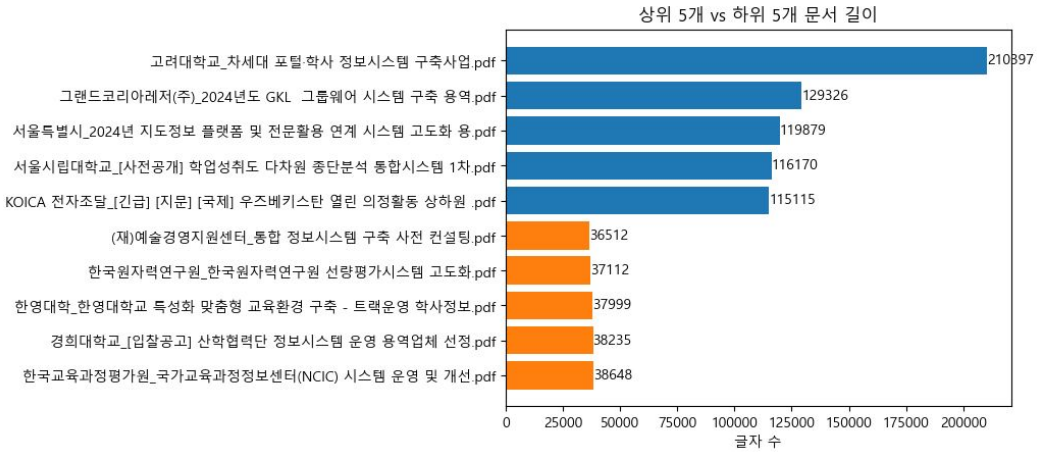

본 분석에서는 문서의 텍스트 길이(글자 수)와 문서 내 표 개수를 기준으로 문서의 구조적 복잡도를 평가

문서 길이는 정보 밀도를 간접적으로 나타냄, 표 개수는 정형화된 데이터 구조의 활용 정도를 의미

상위/하위 문서를 비교함으로써 문서 간 구조적 차이와 내용 규모의 편차를 시각적으로 파악할 수 있음

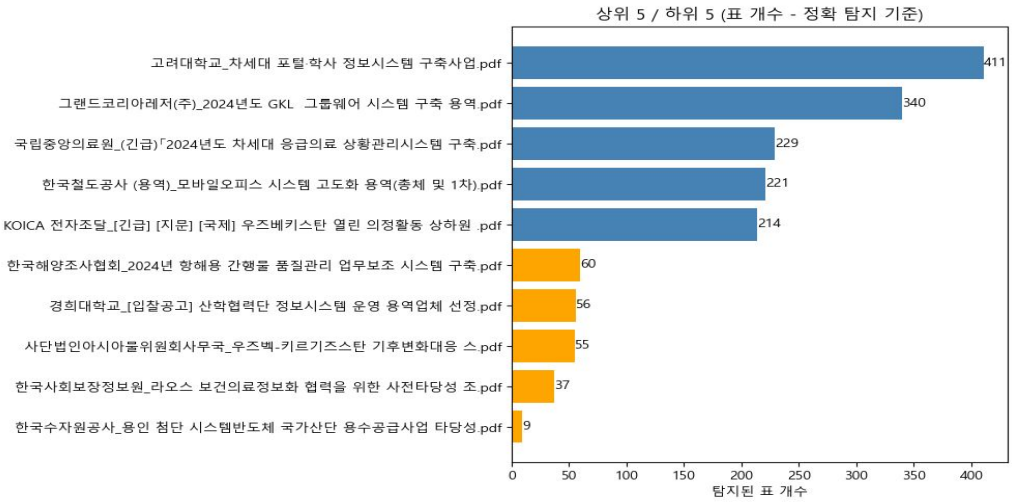

블록기반의 계산이 아닌 테이블 파서 기반으로 계산

- 격자구조
- 라인감지
- 셀 경계 탐지

이는 RAG에 적합

문서 길이와 표 개수는 RAG 시스템에서 검색 단위의 복잡도를 결정하는 주요 요소

텍스트가 길고 표가 많은 문서는 정보 분해 및 임베딩 시
세밀한 분할 전략이 필요할 가능성이 높음

3.2.4. 전처리 통계 < 3.2. 환경 및 전처리 < 3.개발 경과

▣ 벡터 유사도

유사도 0.8 이상 문서 네트워크 (상위 10개)

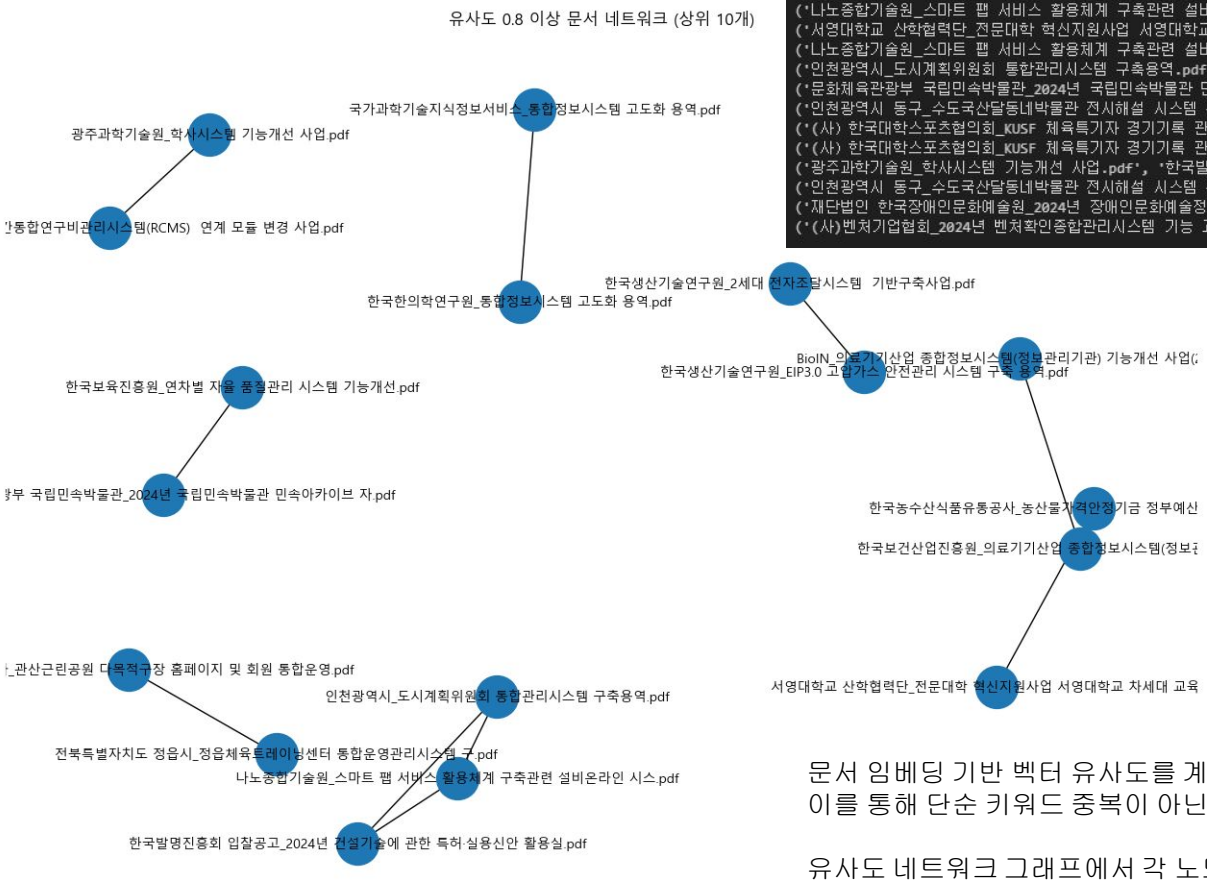


```
유사 문서 쌍 (유사도 > 0.8)
('BioIN_의료기기산업 종합정보시스템(정보관리기관) 기능개선 사업(2차).pdf', '한국보건산업진흥원_의료기기산업 종합정보시스템(정보관리기관) 기능.pdf', 1.0)
('국가과학기술지식정보서비스_통합정보시스템 고도화 용역.pdf', '한국한의학연구원_통합정보시스템 고도화 용역.pdf', 1.0)
('한국생산기술연구원_2세대 전자조달시스템  기반구축사업.pdf', '한국생산기술연구원_EIP3.0 고압가스 안전관리 시스템 구축 용역.pdf', 0.9571)
('광주과학기술원_실시간통합연구비관리시스템(RCMS)  연계 모듈 변경 사업.pdf', '광주과학기술원_학사시스템 기능개선 사업.pdf', 0.94735)
('고양도시관리공사_관산근린공원 다목적구장 홈페이지 및 회원 통합운영.pdf', '전북특별자치도 정읍시_정읍체육트레이닝센터 통합운영관리시스템 구.pdf', 0.93858)
('나노종합기술원_스마트 팹 서비스 활용체계 구축관련 설비온라인 시스.pdf', '인천광역시_도시계획위원회 통합관리시스템 구축용역.pdf', 0.87912)
('서영대학교 산학협력단_전문대학 혁신지원사업 서영대학교 차세대 교육.pdf', '한국농수산식품유통공사_농산물가격안정기금 정부예산회계연계시스템 .pdf', 0.86891)
('나노종합기술원_스마트 팹 서비스 활용체계 구축관련 설비온라인 시스.pdf', '한국발명진흥회 입찰공고_2024년 건설기술에 관한 특허·실용신안 활용실.pdf', 0.86031)
('인천광역시_도시계획위원회 통합관리시스템 구축용역.pdf', '한국발명진흥회 입찰공고_2024년 건설기술에 관한 특허·실용신안 활용실.pdf', 0.85054)
('문화체육관광부 국립민속박물관_2024년 국립민속박물관 민속아카이브 자.pdf', '한국보육진흥원_연차별 자율 품질관리 시스템 기능개선.pdf', 0.83191)
('인천광역시 동구_수도국산달동네박물관 전시해설 시스템 구축(협상에 .pdf', '인천광역시_도시계획위원회 통합관리시스템 구축용역.pdf', 0.82973)
('(사) 한국대학스포츠협의회_KUSF 체육특기자 경기기록 관리시스템 개발.pdf', '대한장애인체육회_2025년 전국장애인체육대회 전산 및 시스템, 홈페이지 .pdf', 0.82626)
('(사) 한국대학스포츠협의회_KUSF 체육특기자 경기기록 관리시스템 개발.pdf', '한국산업인력공단_RFID기반 국가자격 시험 결과물 스마트 관리시스템 도.pdf', 0.82148)
('광주과학기술원_학사시스템 기능개선 사업.pdf', '한국발명진흥회 입찰공고_2024년 건설기술에 관한 특허·실용신안 활용실.pdf', 0.81166)
('인천광역시 동구_수도국산달동네박물관 전시해설 시스템 구축(협상에 .pdf', '한국발명진흥회 입찰공고_2024년 건설기술에 관한 특허·실용신안 활용실.pdf', 0.81037)
('재단법인 한국장애인문화예술원_2024년 장애인문화예술정보시스템 이음.pdf', '한국산업인력공단_RFID기반 국가자격 시험 결과물 스마트 관리시스템 도.pdf', 0.80628)
('(사)벤처기업협회_2024년 벤처확인종합관리시스템 기능 고도화 용역사업 .pdf', '한국농수산식품유통공사_농산물가격안정기금 정부예산회계연계시스템 .pdf', 0.80427)
```

문서 임베딩 기반 벡터 유사도를 계산하여 문서 간 의미적 유사성을 분석
이를 통해 단순 키워드 중복이 아닌 문서 내용 수준에서의 유사 관계를 파악할 수 있음

유사도 네트워크 그래프에서 각 노드는 문서를 의미, 노드를 연결하는 엣지는 유사도 임계값(0.8) 이상인 문서 간 관계를 나타냄.

유사도 1.0에 가까운 문서는 거의 동일한 문서 또는 복사본으로 판단,
RAG 시스템에서는 중복 제거 대상 후보로 분류되나 공고번호가 다르면 제거 하지 않음.

▣ 도메인/키워드 통계

분야	주요 키워드
과학	과학, 과학기술, R&D, 연구개발
IT	AI, HW, SW, 정보기술, 클라우드, 빅데이터, IoT, 데이터, 보안, 소프트웨어
건설	공사, 토목, 건설, 건축
의료	제약, 보건, 의약, 병원, 의료
교육	대학, 연수, 교육, 학교
환경	친환경, 에너지, 환경, 신재생
문화	예술, 문화, 관광, 체육
복지	사회복지, 복지시설, 복지
국방	방위, 군사, 국방
통신	6G, 통신, 네트워크, 5G

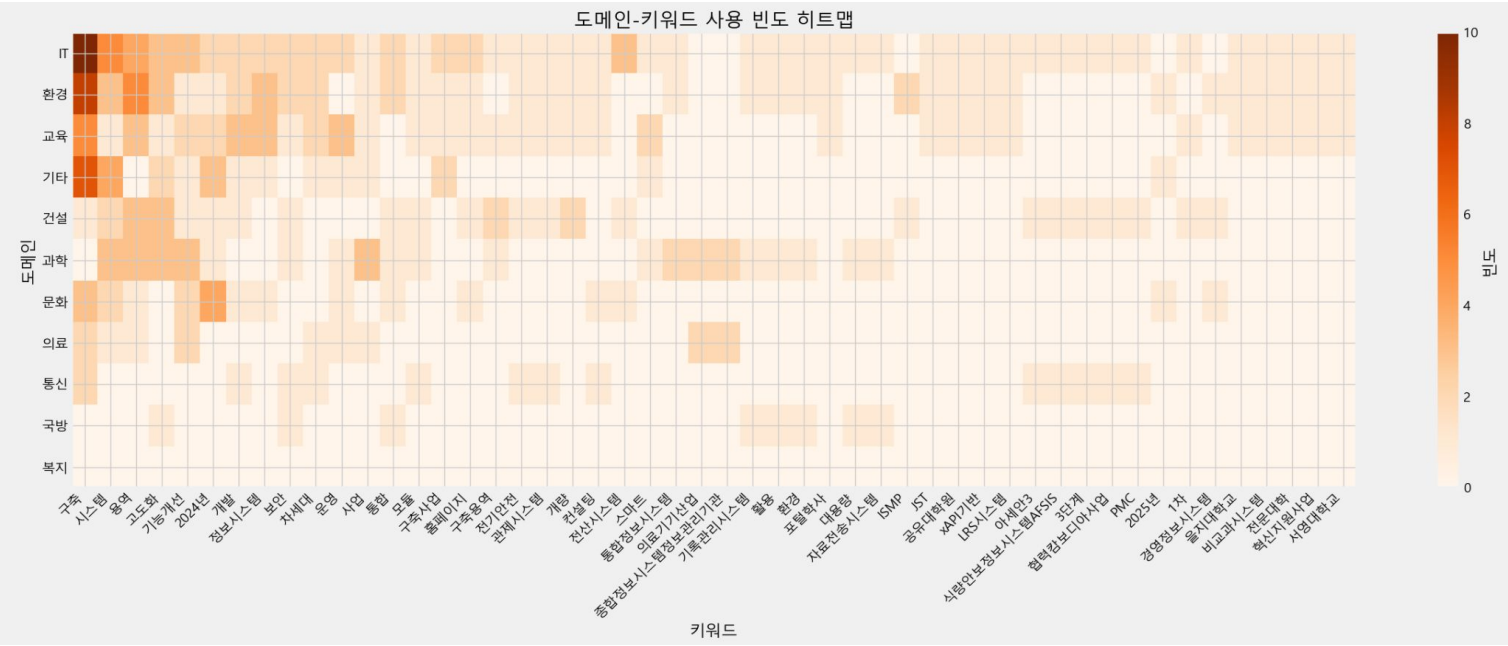

▣ 지역별 도메인 통계

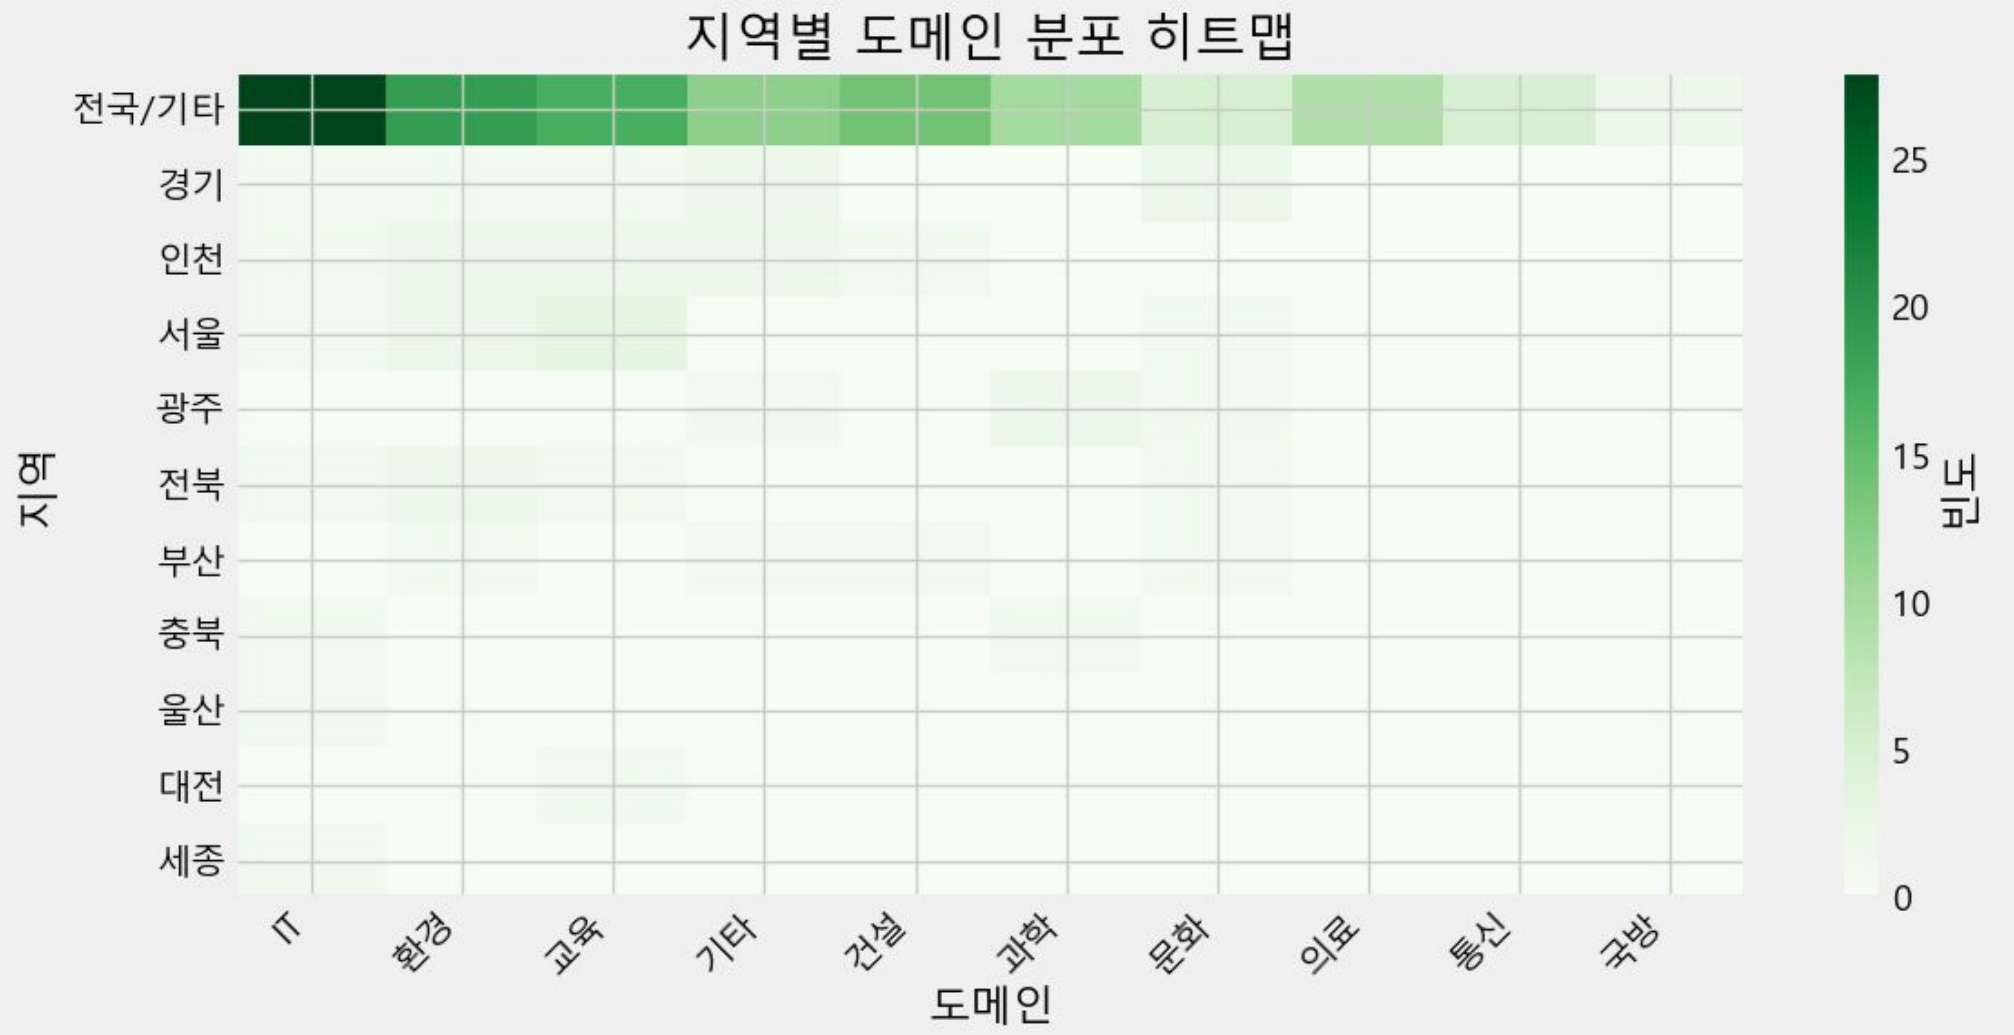
지역별 도메인 분포 히트맵
전국/기타
경기
인천
서울
광주
전북
부산
충북
울산
대전
세종
지역
IT
환경
교육
기타
건설
과학
문화
의료
통신
국방
도메인
25
20
15
10
5
0
개수

▣ 예산별 도메인 통계

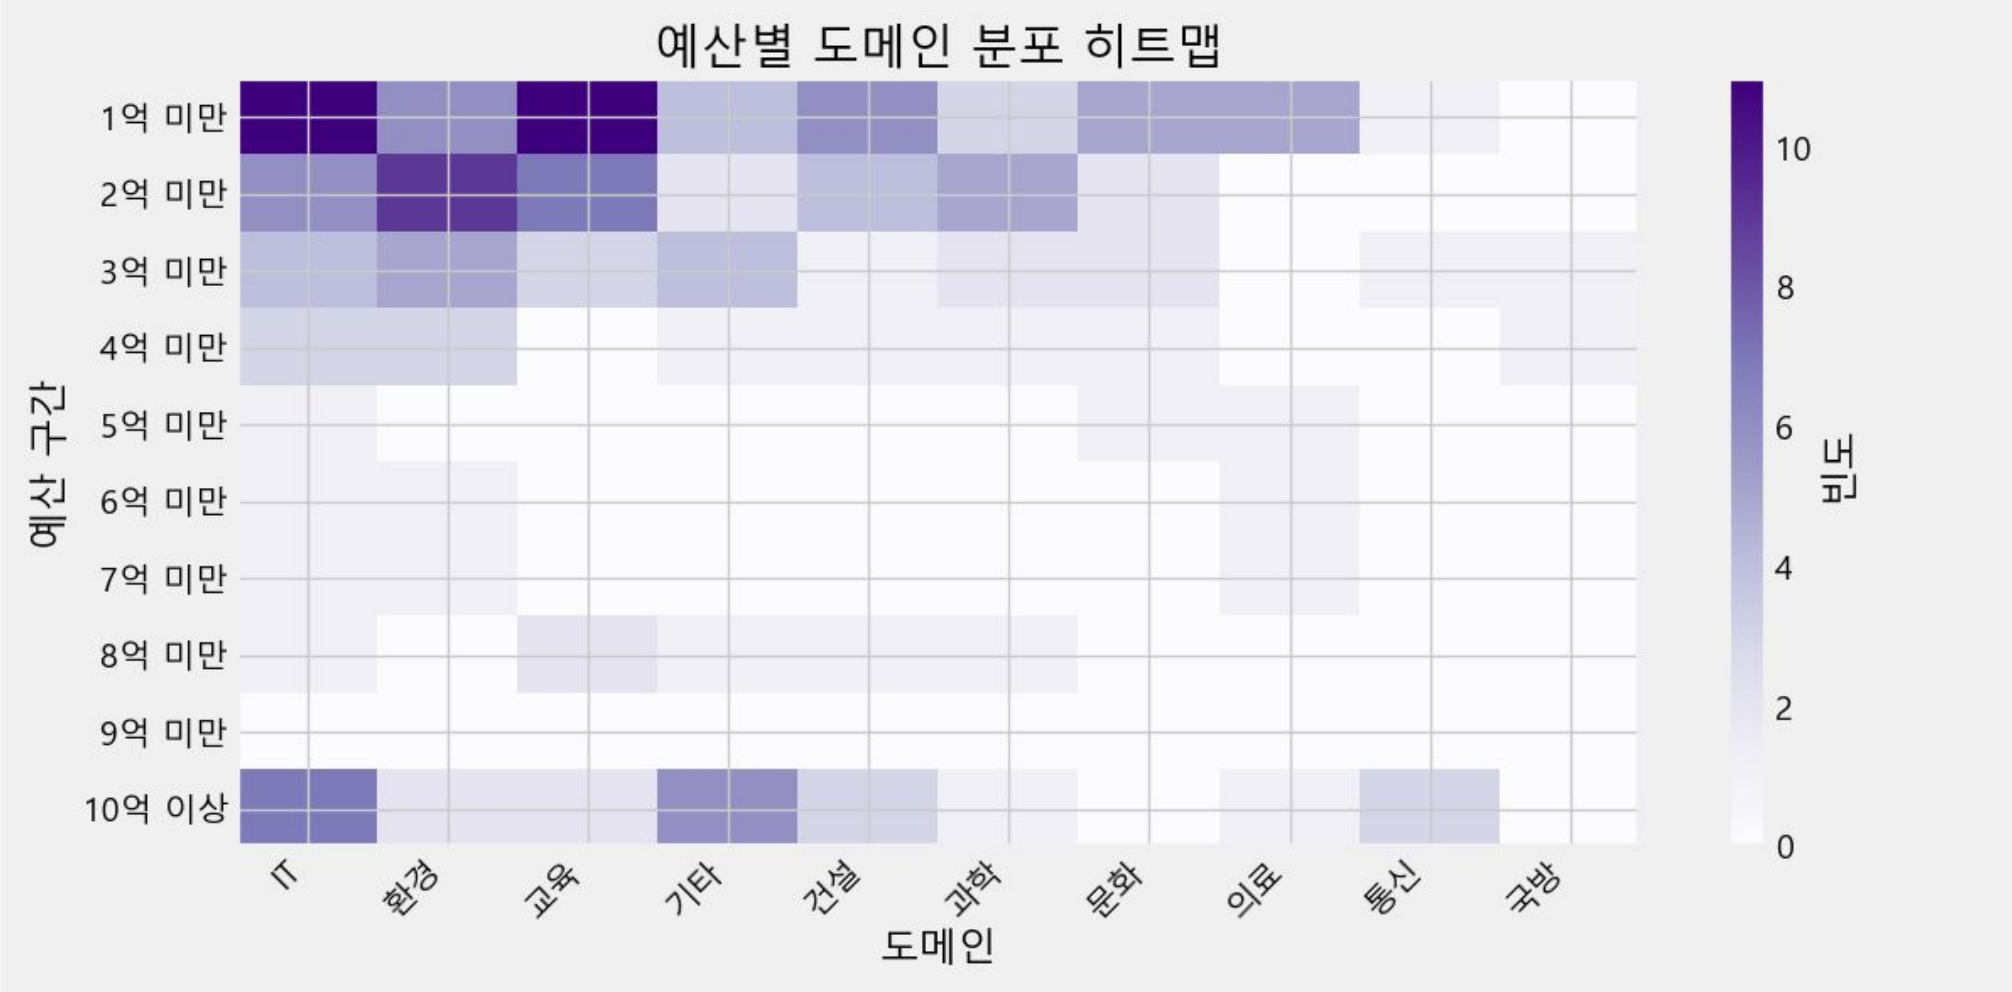
예산별 도메인 분포 히트맵
예산 구간
1억 미만
2억 미만
3억 미만
4억 미만
5억 미만
6억 미만
7억 미만
8억 미만
9억 미만
10억 이상
IT
환경
교육
기타
건설
과학
문화
의료
통신
국방
도메인
빈도
10
8
6
4
2
0

▣ 모델 질의-응답 파이프 라인

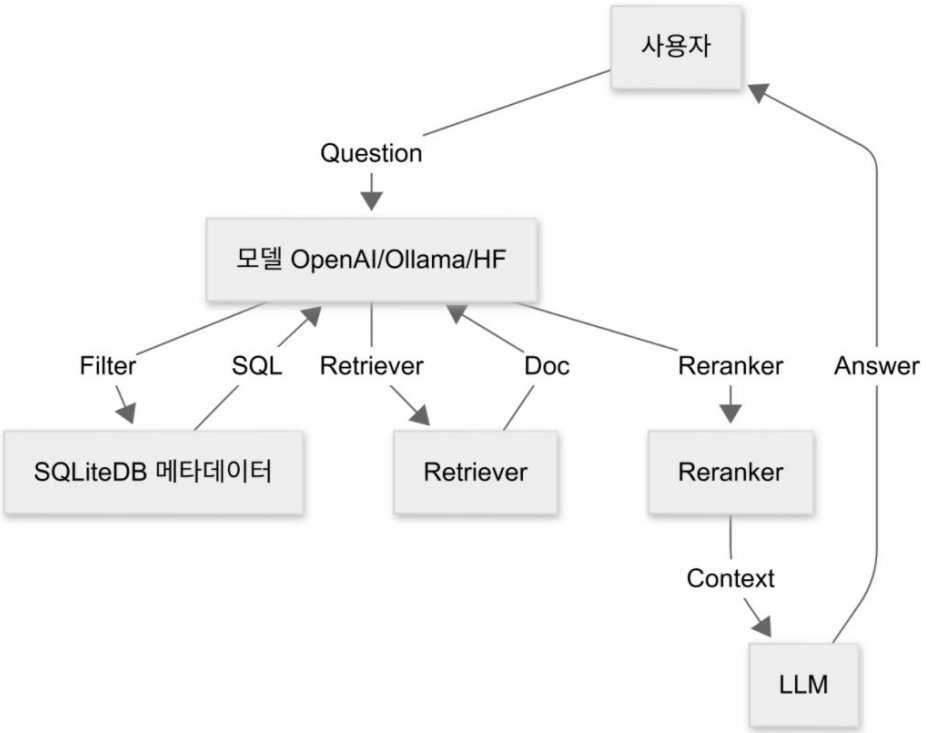

모듈	종류
Model	openai : gpt-5-mini, text-embedding-3-small
	Ollama: exaone3.5:7.8b, bge-m3
	hugging face: nlpai-lab/KULLM3, nlpai-lab/KoE5
Retriever	bm25: BM25 알고리즘을 사용한 전통적인 키워드 기반 검색기.
	vector: 임베딩 벡터를 활용한 유사도 기반 벡터 검색기.
	hybrid: BM25와 벡터 검색을 결합한 하이브리드 검색기.
	llm: LLM(대형 언어 모델)을 활용한 생성형 검색기.
	bm25_llm": BM25 검색 결과를 LLM으로 후처리하는 검색기.
	vector_ll: 벡터 검색 결과를 LLM으로 후처리하는 검색기.
	hybrid_llm: 하이브리드 검색 결과를 LLM으로 후처리하는 검색기.
Reranker	bge: BGE Cross-Encoder 모델을 활용한 의미 기반 리랭킹 방식.
	dense: 임베딩 벡터 유사도를 이용한 단순 벡터 기반 리랭킹 방식.
	OpenAI/Ollama: LLM API(OpenAI 또는 Ollama)를 활용해 문서 관련도를 평가하는 리랭킹 방식.
	hybrid: BGE와 Dense 결합하여 가중 평균으로 리랭킹하는 하이브리드 방식.

▣ 구현 모듈/Class

분류	구성 요소	주요 역할 및 특징
핵심 구조	BaseLLMModel	모든 모델의 공통 로직(검색, 리랭킹, 생성)을 조율하는 최상위 클래스 및 평가 시스템(eval) 포함
추론 엔진	OpenAIModel	OpenAI API 활용. GPT-5-mini 등 고성능 클라우드 모델을 통해 안정적인 답변 성능 제공
추론 엔진	OllamaModel	로컬 서버 활용. EXAONE3.5 등 오픈소스 모델을 사용해 데이터 보안 및 비용 절감 가능
추론 엔진	HugginFaceModel	GPU 환경 직접 구동. KULLM3 등 국산 오픈소스 모델을 활용한 최적화된 한국어 처리
이력 관리	HistoryManager	세션의 질의/응답에 대한 History를 제공.
지능형 분석	QueryFilterExtractor	LLM과 정규표현식을 결합하여 질문에서 예산, 기관, 분야 등 검색 필터를 자동 추출
데이터 검색	SQLSearchHelper	단순 문서 검색을 보완하여 SQLite DB로부터 사업명, 금액 등 정형화된 정보를 정확히 조회
데이터 검색	SQLiteDB	수집된 모든 사업 공고의 메타데이터 및 검색 결과를 저장하고 관리하는 핵심 DB 모듈

▣ 구현 모듈/Class

분류	구성 요소	주요 역할 및 특징
기본 검색	BM25RetrieverModule	키워드 일치 기반 검색. 특정 단어가 포함된 문서를 찾는 데 효과적이며 연산 속도가 빠름
의미 검색	VectorRetrieverModule	FAISS 임베딩 기반 검색. 단어의 의미적 유사성을 파악하여 문맥에 맞는 문서를 찾아냄
복합 검색	HybridRetriever	BM25와 Vector 검색의 장점을 결합. 가중치(Alpha)를 조절하여 키워드와 의미의 비중을 최적화
지능형 검색	MultiQueryRetriever	LLM을 사용하여 하나의 질문을 여러 개로 재해석(Rewriting). 검색 범위를 넓혀 정답 확률을 높임
통합 모듈	MultiQueryHybridRetrieverModule	위 모든 검색 방식을 포함하는 통합 컨트롤러. 설정에 따라 최적의 검색 알고리즘을 조합하여 생성
팩토리 함수	build_retriever_from_param	파라미터 설정을 기반으로 실시간으로 필요한 검색기(Retriever) 객체를 생성하여 반환

▣ 구현 모듈/Class

분류	구성 요소	주요 역할 및 특징
핵심 클래스	Reranker	리랭킹 로직의 통합 관리 클래스. 중복 제거 및 설정된 타입에 따른 재정렬 프로세스 제어
로컬 리랭킹	_bge_rerank	BGE Cross-Encoder 모델 활용. 로컬 GPU/CPU에서 문장 간 유사도를 정밀하게 계산 (고성능 추천 방식)
유사도 리랭킹	_dense_rerank	임베딩 벡터 간의 코사인 유사도를 기반으로 재정렬. 단순하지만 효율적인 계산 방식
지능형 리랭킹	_llm_rerank	OpenAI/Ollama 등 **LLM이 직접 문서의 관련도를 점수화(0~5점)**하여 가장 유의미한 정보 선별
복합 리랭킹	_hybrid_rerank	BGE(의미론적 분석)와 Dense(벡터 유사도)의 점수를 가중 평균하여 다각도에서 순위 재산출
보조 기능	_deduplicate_docs	리랭킹 수행 전, 본문 내용을 기준으로 중복되거나 중첩되는 문서를 제거하여 콘텍스트 효율화

▣ 웹서비스 비교

항목	Streamlit	Reflex	FastAPI
주 용도	데이터 앱, 대시보드 제작	풀스택 웹앱 개발 (프론트+백엔드)	고성능 API 서버 개발
개발 난이도	매우 쉬움	중간	중간
프론트엔드 지식 필요 여부	거의 불필요	거의 불필요 (React 기반 자동 생성)	필요 (별도 프론트엔드 개발 필요)
백엔드 제어	제한적	가능	매우 강력
비동기 지원	제한적	지원	강력한 async 지원
성능	보통	보통	매우 우수 (ASGI 기반)
학습 곡선	낮음	중간	중간
배포 방식	Streamlit Cloud 등	자체 서버 또는 클라우드	Uvicorn/Gunicorn 기반 배포
확장성	소규모/프로토타입에 적합	중소규모 웹앱	대규모 서비스에 적합
대표 사용 사례	ML 모델 데모, 데이터 시각화	SaaS 웹앱, 내부관리 시스템	REST API, 마이크로서비스
장점	빠른 개발, 코드 간결	Python만으로 풀스택 가능	속도 빠름, 타입 기반 자동 문서화
단점	복잡한 앱 구조에 한계	생태계가 비교적 작음	프론트엔드 별도 개발 필요

▣ Reflex선정 이유

- 풀스택을 지원
- 프론트엔드 지식 거의 불필요.
- 상태 변경시 부분 업데이트 가능.

▣ 구현 모듈/Class

분류	구성 요소	주요 역할 및 특징
메인 앱	app.py	애플리케이션의 진입점. 전체 레이아웃 구성을 위한 탭 트리거 정의 및 각 페이지 모듈 연결
화면 모듈	summary.py	프로젝트 리포트 요약.doc 폴더의 PDF 파일을 Base64로 인코딩하여 반응형 뷰어로 출력
화면 모듈	openai.py	OpenAI RAG 검색. 클라우드 LLM을 사용하여 질문에 답변하고, SQLite 메타데이터 검색 옵션 제공
화면 모듈	ollama.py	Ollama 로컬 검색. 로컬에 설치된 LLM(EXAONE 등)을 활용한 질의응답 인터페이스 제공

▣ 웹서비스 파이프라인

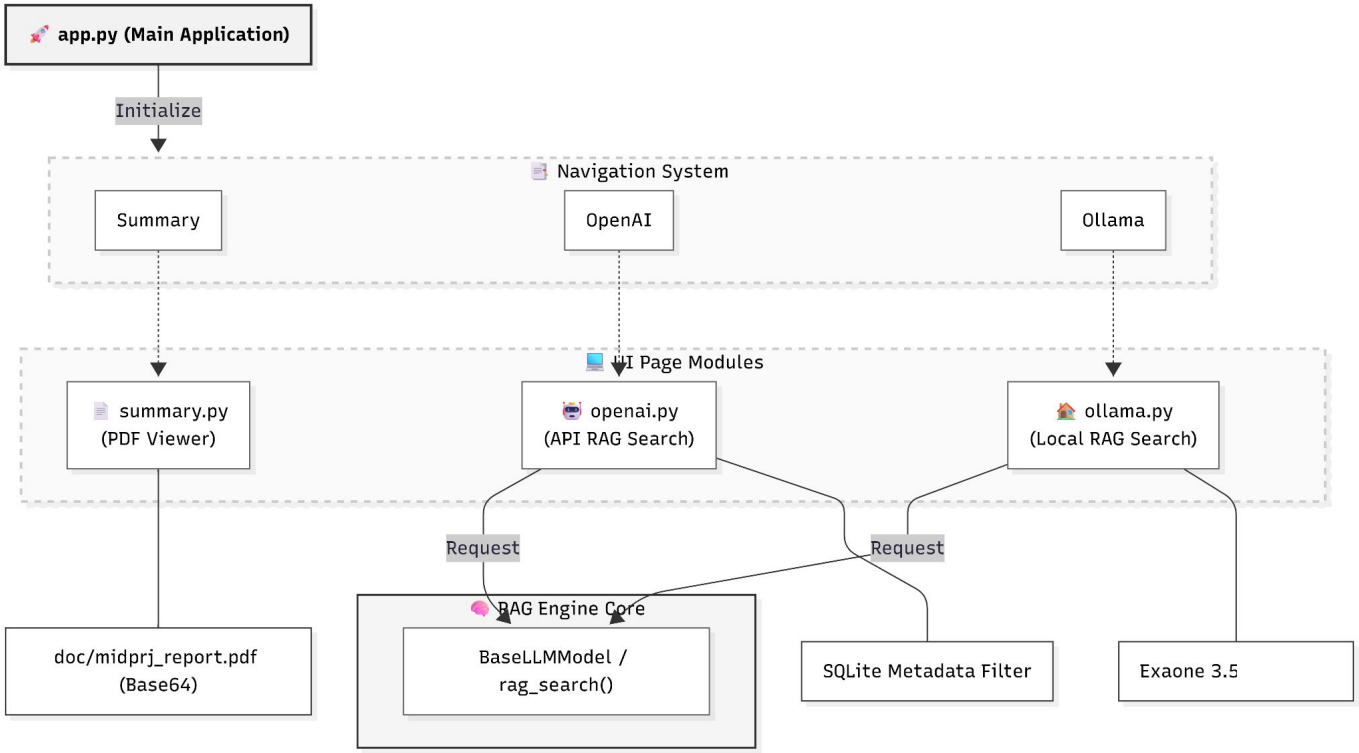

▣ 평가 방법

방안 : openai llm gpt-5-mini를 이용해서 평가

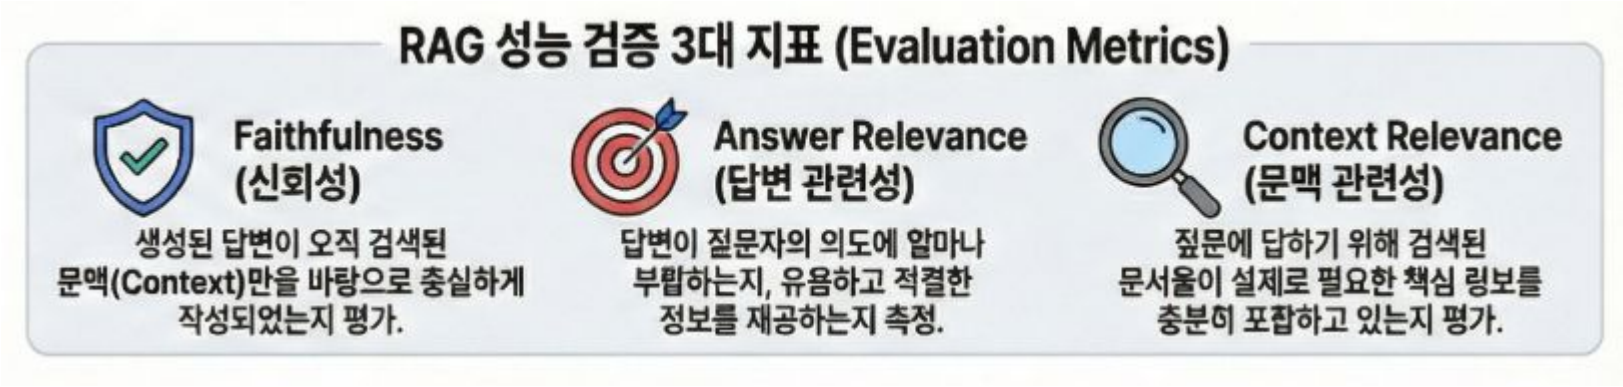

▣ 평가 질의(7개)

- 예산이 1억 이상 3억 이하의 제안요구서를 알려 줘.
- 교육 관련 이면서 IT 관련 제안요구서를 찾아 줘.
- 이전 질문과 관련해서 콘텐츠 개발 관리 및 모니터링 업무 요구사항을 더 자세히 알려 줘.
- 국민연금공단 이러닝시스템 관련 사업 요구사항을 정리해 줘.
- 이전 질문과 관련해서 교육·학습 관련 타 기관 발주 사업이 있는지 알려 줘.
- 주요 기관(예: 기초과학연구원, 한국원자력연구원) 사업의 AI 예측·사업 목적을 설명해 줘.
- 1년 이상의 사업 기간이 요구되는 제안요구서를 찾아 줘

3.4.1. 옵션 평가 < 3.4.평가 < 3.개발 경과

▣ 평가 방법

poenai/ollama에서 retriever(retriever=hybrid_llm)/reranker(bge)로 고정하고
temperature/repetition_penalty/chunk_size/chunk_overlap/k 평가.

▣ 평가 결과

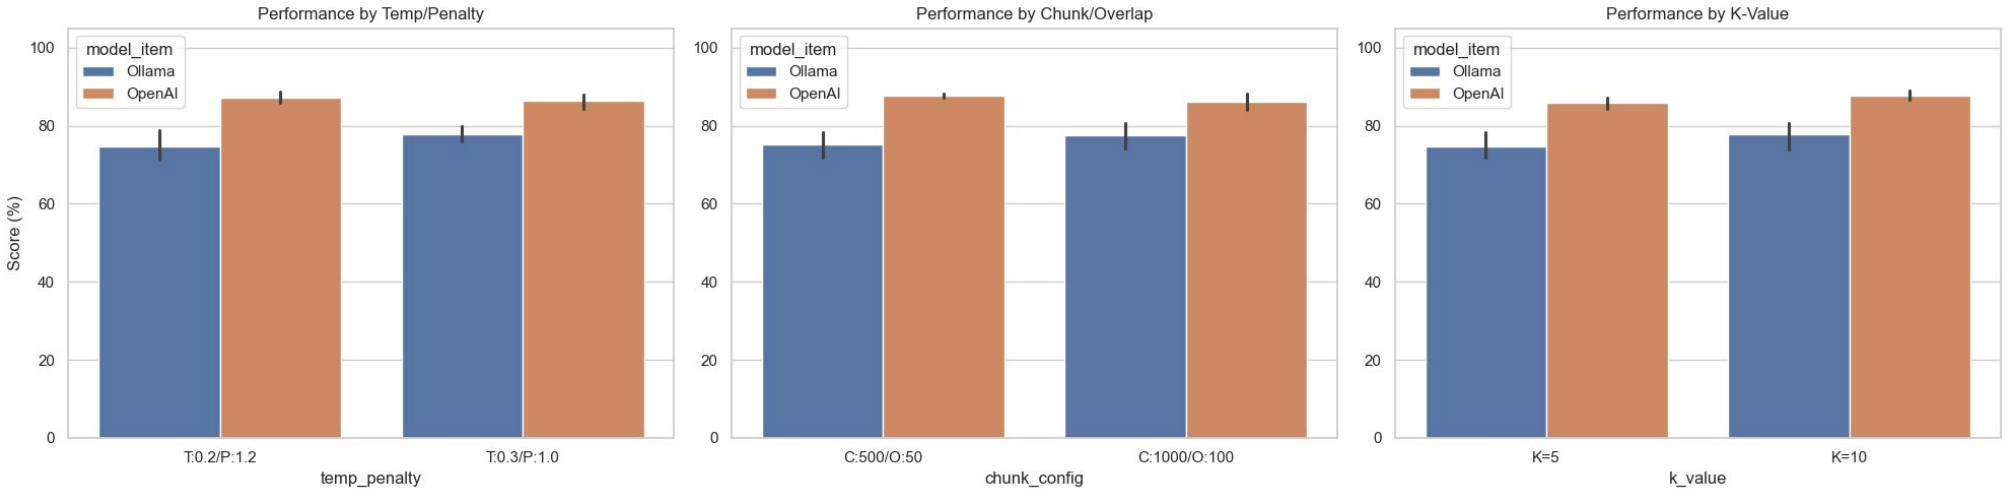

▣ 옵션 지수 결정

모델	temperature	repetition_penalty	chunk_size	chunk_overlap	k
gpt-5-min	0.0 (완전한 사실 기반, 0.1보다 더 엄격)	1.1 (정확성 강조)	400 (300보다 늘려 의미 단절 방지)	40 (청크 연결성 확보)	4 (상위 4개 문서만 활용)
exaone3.5:7.8b	0.2 (문장 흐름을 위한 약간의 유연성)	1.05 (한국어 문장 딱딱함 방지)	1000 (1200보다 줄여 컨텍스트 최적화)	150 (충분한 오버랩으로 문맥 유지)	13 (풍부한 정보량 제공)

3.4.2. retriever/reranker 평가 < 3.4.평가 < 3.개발 경과

▣ 아래 옵션으로 테스트 했을 경우에

top3

모델	temperature	repetition_penalty	chunk_size	chunk_overlap	k
gpt-5-min	0.0	1.1	400	40	4
exaone3.5:7.8b	0.2	1.05	1000	150	13

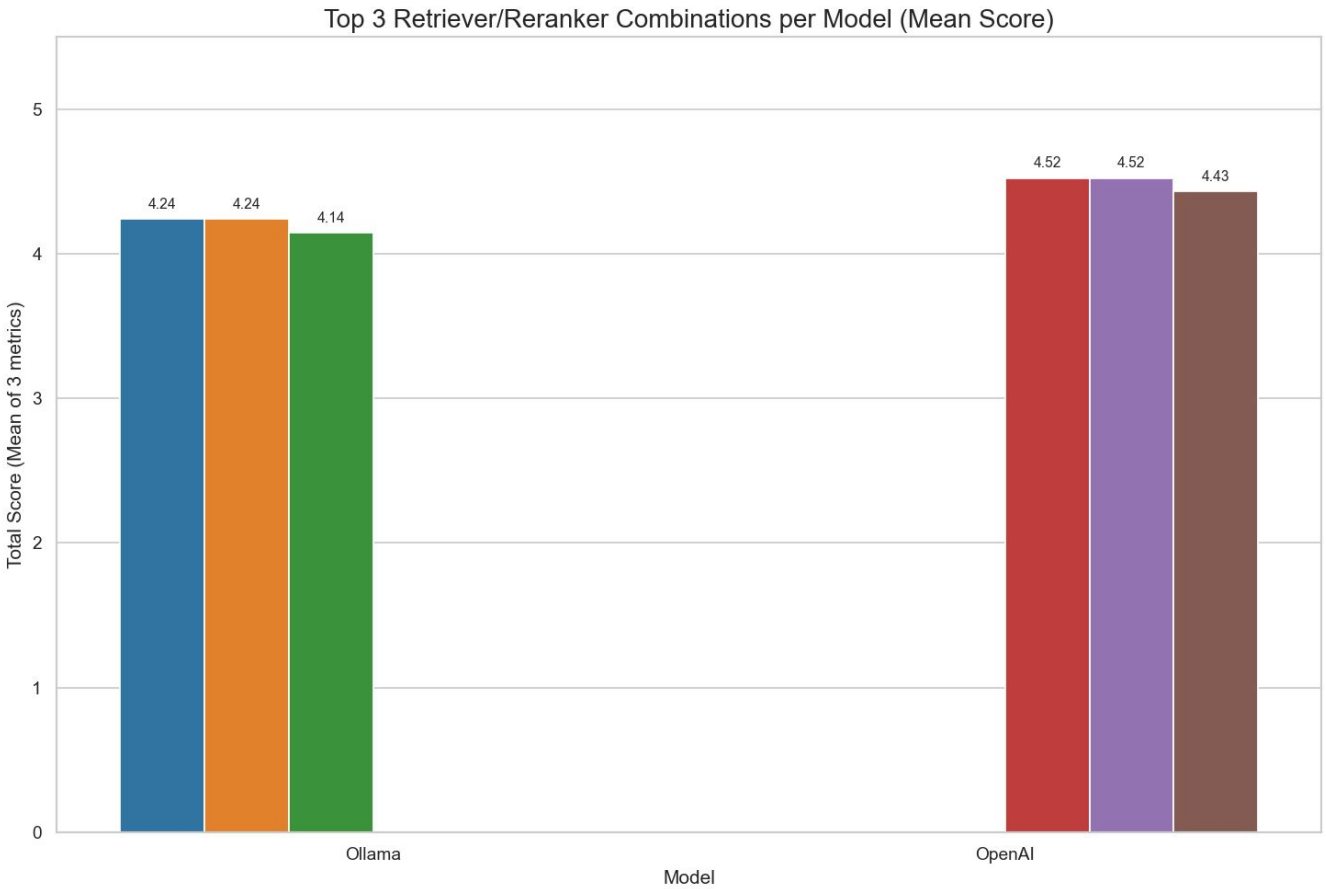

color	retriever	reranker
	hybrid	llm
	vector	hybrid
	bm25	hybrid
	vector	bge
	llm	llm
	bm25_lm	hybrid

4. 시연

App | Index
localhost:3000
Summary
OpenAI
Ollama
프로젝트 리포트 요약
midprj_report
1 / 17
100%
RFP 분석을 위한 지능형 RAG시스템
(코드잇 6기 1팀)
2026년 02월

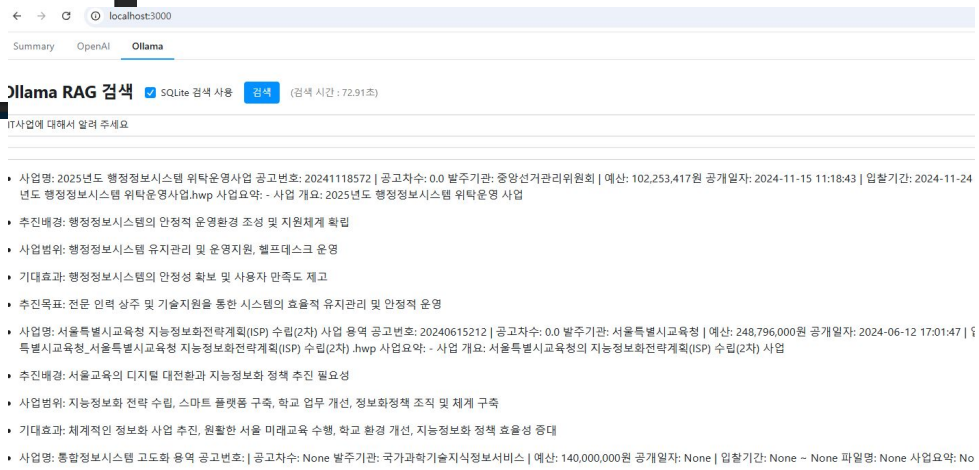
localhost:3000
Summary
OpenAI
Ollama
llama RAG 검색
SQLite 검색 사용
검색
(검색 시간 : 72.91초)
IT사업에 대해서 알려 주세요
사업명: 2025년도 행정정보시스템 위탁운영사업 공고번호: 20241118572 | 공고차수: 0.0 발주기관: 중앙선거관리위원회 | 예산: 102,253,417원 공개일자: 2024-11-15 11:18:43 | 입찰기간: 2024-11-24 년도 행정정보시스템 위탁운영사업.hwp 사업요약: - 사업 개요: 2025년도 행정정보시스템 위탁운영 사업
추진배경: 행정정보시스템의 안정적 운영환경 조성 및 지원체계 확립
사업범위: 행정정보시스템 유지관리 및 운영지원, 헬프데스크 운영
기대효과: 행정정보시스템의 안정성 확보 및 사용자 만족도 제고
추진목표: 전문 인력 상주 및 기술지원을 통한 시스템의 효율적 유지관리 및 안정적 운영
사업명: 서울특별시교육청 지능정보화전략계획(ISP) 수립(2차) 사업 용역 공고번호: 20240615212 | 공고차수: 0.0 발주기관: 서울특별시교육청 | 예산: 248,796,000원 공개일자: 2024-06-12 17:01:47 | 특별시교육청_서울특별시교육청 지능정보화전략계획(ISP) 수립(2차) .hwp 사업요약: - 사업 개요: 서울특별시교육청의 지능정보화전략계획(ISP) 수립(2차) 사업
추진배경: 서울교육의 디지털 대전환과 지능정보화 정책 추진 필요성
사업범위: 지능정보화 전략 수립, 스마트 플랫폼 구축, 학교 업무 개선, 정보화정책 조직 및 체계 구축
기대효과: 체계적인 정보화 사업 추진, 원활한 서울 미래교육 수행, 학교 환경 개선, 지능정보화 정책 효율성 증대
사업명: 통합정보시스템 고도화 용역 공고번호: | 공고차수: None 발주기관: 국가과학기술지식정보서비스 | 예산: 140,000,000원 공개일자: None | 입찰기간: None ~ None 파일명: None 사업요약: No

5. 회고 및 향후 과제

회고

- 실무에서도 바로 사용 가능한 시스템을 만드는 것을 목표로 구현.
- 인터넷서비스(openai), cloud,local 사용의 전환이 용이.
- Model에 추상화 계층을 두어서 같은 인터페이스로사용가능하도록 함.
- 주요 기능을 모듈화 해서 추후에 확장이 가능 함.
- 정형/비정형 데이터의 복합 검색을 통해서 RFP의 정확도를 높임.

향후 과제

- **점진적인 vector update 방안 필요.(파일 하나 추가할때마다, meta정보/domain/keyword/vector 자동 Update필요)**
- SQLite Filter를 통해서 나온 결과와 정확성에 대한 정량적 평가 필요.
- 테스트를 SQLite를 모두 사용하는 것으로 점수를 산정 했으나, 사용/미사용으로 테스트가 필요.
- 리포트 형태의 초안을 만드는 워크플로우 필요.
- 한글 파일의 분석 자동화.
- 응답의 가시성 올리는 방안.